

MINISTÉRIO DA DEFESA
EXÉRCITO BRASILEIRO
DEPARTAMENTO DE CIÊNCIA E TECNOLOGIA
INSTITUTO MILITAR DE ENGENHARIA
CURSO DE MESTRADO EM SISTEMAS E COMPUTAÇÃO

PROPOSTA DE DISSERTAÇÃO DE MESTRADO

DANILLO MARCUS FARIAS MARINHO DO MONTE

APLICAÇÃO DAS REDES NEURAIS CONVOLUCIONAIS
(CNN) NA IDENTIFICAÇÃO E CLASSIFICAÇÃO DE
PATOLOGIAS EM PAVIMENTOS RODOVIÁRIOS

Rio de Janeiro
2024

1 TÍTULO DA PROPOSTA DE DISSERTAÇÃO

Título da Proposta de Dissertação:

APLICAÇÃO DAS REDES NEURAIS CONVOLUCIONAIS (CNN) NA
IDENTIFICAÇÃO E CLASSIFICAÇÃO DE PATOLOGIAS EM PAVIMENTOS
RODOVIÁRIOS

Área de Concentração:

Ciência da Computação

Linha de Pesquisa:

ENGENHARIA DE SISTEMAS E INFORMAÇÃO

2 INTRODUÇÃO

A crescente evolução das tecnologias e a constante necessidade de implantação/manutenção/conservação das rodovias, torna necessário o contínuo desenvolvimento de projetos de pesquisas, desenvolvimento e inovações tecnológicas para o crescimento de um país que tem como principal modal o rodoviário, assim como é no Brasil.

Especificamente, a aplicação de tecnologias inovadoras em sistemas de gerenciamento de pavimentos, como o *Pavement Scanner*, *Falling Weight Deflectometer FWD*, Veículos Aéreos não Tripulados *VANTS*, dentre outros, resulta em modelos preditivos de conservação/manutenção que podem aumentar a vida útil dessas estruturas, bem como aumentar a segurança das rodovias.

Tendo em vista que o bom desempenho dos pavimentos está ligado diretamente ao seu estado de conservação e a sua capacidade de fluxo de veículos leves e pesados, a desintegração das suas estruturas compromete seriamente o seu nível operacional. O que pode contribuir com bom desempenho dos pavimentos é a detecção e a caracterização precoce das patologias, tornando oportuna a manutenção preventiva das estruturas atingidas.

Para tanto, os órgãos responsáveis pelas malhas existentes no país desenvolveram normas e procedimentos padronizados que estabelecem métodos avaliativos das condições dos pavimentos identificando os problemas existentes e o grau de severidade das ocorrências encontradas. Os levantamentos destinados a avaliação objetiva da superfície de pavimentos, segundo os normativos do Departamento Nacional de Infraestrutura de Transportes (DNIT), geram importantes indicativos do grau de deterioração destes, citando como principais resultados: Índice de Condição dos Pavimentos (ICP), Quociente de Irregularidade (QI), e o Índice de Gravidade Global (IGG). Essas avaliações, para pavimentos flexíveis e semi-rígidos, são embasados pela Norma 006 DNIT (2003) que determina os procedimentos avaliativos. Já para os pavimentos rígidos, as inspeções visuais são balizadas pela Norma 060 DNIT (2004).

No entanto, apesar do surgimento de métodos modernos para a obtenção de informações com relação as condições dos pavimentos, estes apresentam altos custos operacionais. Sendo assim, a detecção das patologias no pavimento é, na grande maioria, realizada através de métodos visuais, utilizando-se dispositivos móveis ou não, apontadas por um avaliador que identifica e classifica visualmente fissuras, trincas, buracos, panelas e outros defeitos da superfície dos pavimentos. No entanto, esses métodos já estão em desuso por

apresentarem diversas limitações incluindo subjetividade, baixa precisão e inconsistência, além de riscos ao avaliador (HE et al., 2020).

Com o intuito de vencer as limitações existentes nos métodos convencionais, pesquisadores e profissionais passaram a explorar novas técnicas de inspeção, dentre elas, a utilização de aprendizado de máquina. Técnicas de detecção de borda foram inicialmente utilizadas para estabelecer limites de fissura, com base na mudança de intensidade ou cor. Já a limiarização definia um limiar específico de cor e a análise de textura extraía características texturais. No entanto, essas técnicas apresentavam diversas limitações gerando resultados falsos positivos, limites na capacidade de captura e imprecisão (ASHRAF et al., 2023).

Contudo, com o avanço da inteligência artificial (IA) e com o acesso a recursos computacionais com maior capacidade de processamento, bem como a redução dos custos de aquisição, as abordagens voltadas para aprendizado de máquina estão sendo cada vez mais utilizadas na detecção de patologias em pavimentos rodoviários. Em uma Revisão Sistemática da Literatura (RSL) realizada recentemente, foi constatado que a utilização de Redes Neurais Convolucionais (CNN – *Convolution Neural Network*) tem sido a técnica de Aprendizado Profundo (DP) mais usual na resolução desses casos. Diversos estudos apresentaram testes com várias arquiteturas as quais demonstraram um bom desempenho na identificação de trincas. No entanto, poucos realizam a identificação e classificação de outras patologias como: panelas, buraco, remendo, trilhas de rodas, dentre outras. Dentre as arquiteturas mais usuais estão: AlexNet, SqueezeNet, ResNet, DenseNet, VGG e YOLO. As redes VGG e YOLO são as que apresentaram os melhores rendimentos com melhor acurácia e validação. Outros estudos também demonstraram a utilização de técnica como SVM, LigthGBM e Árvore de Decisão sendo a SVM a rede que apresenta melhores rendimentos.

Com relação aos pavimentos, como mencionado anteriormente, estes são divididos em pavimentos flexíveis, semi-rígidos e rígidos. Sendo que, para cada tipo de estrutura são apresentadas características patológicas diferentes, o que exige que as redes neurais a serem utilizadas possuam uma maior capacidade de aprendizagem. Isso justifica o uso das Redes Neurais Convolucionais por possuírem camadas de neurônios mais profunda o que possibilita um maior aprendizado da rede.

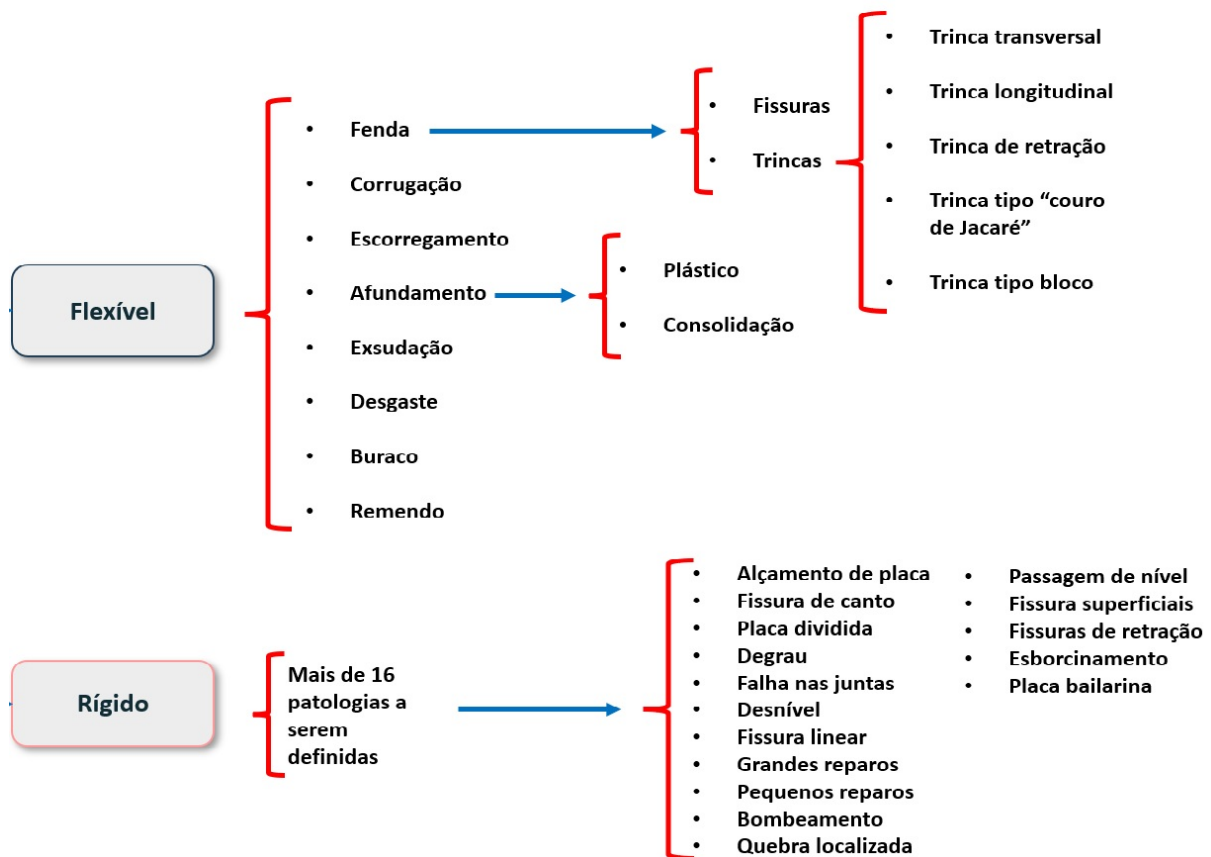


FIG. 2.1: Diagrama das patologias - Pavimento rígido e flexível

Em face ao contexto apresentado, esse trabalho propõe o emprego de uma arquitetura que tenha a capacidade de identificar e classificar as principais patologias tanto em pavimentos flexíveis quanto nos pavimentos rígidos utilizando Rede Neural Convolutiva (CNN). Posteriormente, esse sistema poderá ser embarcado em um dispositivo móvel para realização de reconhecimento em tempo real.

2.1 MOTIVAÇÃO

O desempenho dos pavimentos está ligado diretamente com a sua conservação e capacidade de fluxo de veículos leves ou pesados. A desintegração das suas estruturas pode ocasionar danos prematuros ou até mesmo irreversíveis, sendo necessárias intervenções onerosas para sua recuperação. O que pode contribuir com um bom desempenho dos pavimentos é a detecção e caracterização precoce das patologias, tornando oportuna a manutenção preventiva e eficaz das estruturas atingidas (FENG et al., 2020). O surgimento das trincas/fissuras nas camadas de rolamento está entre os principais fatores que

contribuem para os danos do pavimento por não serem patologias apenas superficiais e, na grande maioria, já são reflexo de danos nas camadas adjacentes o que compromete a vida útil das estruturas (DONG et al., 2016). Com o aumento constante do tráfego nas rodovias, a manutenção preventiva dos pavimentos tem sido cada vez mais importante. Portanto, a identificação previa e os reparos preventivos podem mitigar custos e aumentar a segurança dos veículos e condutores.

Segundo a Confederação Nacional de Transportes (CNT), registrou-se um aumento de veículos da ordem de 52,1% no período de 10 anos (2012-2022). No entanto, a falta de planejamento dos recursos destinados a conservação/manutenção das rodovias tem contribuído para a deterioração dos ativos existentes. Além disso, houve um aumento de apenas 2,5% das rodovias pavimentadas no país se contrapondo ao aumento exacerbado do número de veículos em circulação, o que provoca sobre carga no sistema. (COSTAS et al., 2023)

A pesquisa da CNT (2023) ressalta ainda que a manutenção preventiva é de suma importância para um bom pavimento. Frisa que a os defeitos e as irregularidades na condição da superfície impactam diretamente os custos operacionais para os transportadores e os demais usuários da via, em virtude dos maiores gastos com a manutenção dos veículos, com o consumo de combustível e pneus e com o aumento do tempo de viagens, além de impactar diretamente na economia local podendo provocar aumento nos insumos básicos em detrimento do aumento no custos dos transportes.

Ademais, o volume de malha rodoviária existente em todo território nacional ultrapassam 1 milhão de km, sendo cerca de 213.500 km pavimentadas e subdividas em: Federais, Estaduais e Municipais. Os números implicam em que aproximadamente 12% das rodovias são pavimentadas mas, devido a grande extensão territorial, o acompanhamento e fiscalização das condições dos ativos se tornam complexos e onerosos. Os métodos tradicionais de inventário da condição de superfície dos pavimentos, como: Levantamento Visual Detalhado (LVD), Índice de Condições do Pavimento (ICP), dentre outros, utilizam métodos eficazes mas pouco eficientes, tendo em vista a extensa malha e tempo necessário para conclusão de cada levantamento.

Segundo Nguyen et al. (2023), a detecção de problemas pode ser feita de forma tradicional. No entanto, o método requer muito tempo e consome uma grande quantidade de mão-de-obra e oferece riscos aos técnicos. Portanto, muito estudos tem sido desenvolvidos com métodos autônomos para superar as deficiências dos métodos tradicionais. Nesse contexto, a popularidade do aprendizado profundo, ou *Deep Learning* (DL), que é uma técnica de *Machine Learning* (ML) que usa redes neurais multicamadas tem crescido

significativamente por oferecer vantagens no aprendizado de máquina. Em específico, tem se usado os modelos de Redes Neurais Convolucionais (CNN).

Em uma revisão da literatura realizada na base *Scopus*, foram encontrados 209 artigos que versam a respeito do uso de DL, mais especificamente (CNN) em um período restringido aos trabalhos publicados nos últimos 5 anos contanto a partir de 2019 até 2023.




FIG. 2.2: Artigos publicados na base *Scopus*

Os dados mostrados na FIG. 2.2 mostram que houve uma crescente produção científica no que diz respeito a temática deste trabalho. Os 209 trabalhos selecionados para análise desta revisão foram responsáveis por 1852 citações nas bases de referência. Veja que os artigos publicados em 2019 e 2021 tiveram uma grande contribuição sendo citados 546 vezes e 515 vezes respectivamente. Os demais anos também deram as suas contribuições. Além disso, de 2019 a 2023 houve um aumento nas publicações de aproximadamente 40% utilizando os temas que se referem a pavimentos asfálticos.

Esse aumento de produção científica, especialmente nos anos mais recentes, reflete a crescente relevância e demanda por pesquisas que envolvem o uso de redes neurais para identificação de defeitos em pavimentos rodoviários, demonstrando constante expansão e aprofundamento do tema.

Através de filtros utilizados na revisão da literatura, dos 209 trabalhos encontrados, foram selecionados os 10 trabalhos mais relevante e mais recentes, que utilizam majoritariamente Redes Neurais Convolucionais para resolução dos problemas.

TAB. 2.1: Artigos selecionados.

Citações	Título e Autor
160	<i>Deep Machine Learning Approach to Develop a New Asphalt Condition Index</i> (MAJIDIFARD et al., 2020).
46	<i>One stage detector (RetinaNet)-based crack detection for asphalt pavements considering pavement distresses and surface objects</i> (NGUYEN et al., 2023).
44	<i>Pavement Crack Detection and Segmentation Method Based on Improved Deep Learning Fusion Model</i> (FENG et al., 2020).
13	<i>Deep Learning-Based Crack Detection: A Survey</i> (CHA et al., 2017).
11	<i>A Novel Approach for Detection of Pavement Crack and Sealed Crack Using Image Processing and Salp Swarm Algorithm Optimized Machine Learning</i> (HOANG et al., 2022).
3	<i>Deep Discriminant Learning-based Asphalt Road Cracks Detection via Wireless Camera Network</i> (CAO et al., 2019).
3	<i>Detection of Asphalt Pavement Cracks Based on Vision Transformer Improved YOLO V5</i> (WANG et al., 2023).
1	<i>Application of machine learning for crack detection on concrete structures using CNN architecture</i> (PADMAPOORANI; SENTHILKUMAR, 2023).
0	<i>Computer Vision-Based Recognition of Pavement Crack Patterns Using Light Gradient Boosting Machine, Deep Neural Network, and Convolutional Neural Network</i> (HOANG; NGUYEN, 2023).
0	<i>Deep Learning Techniques for Multi-class Classification of Asphalt Damage Based on Hamburg-Wheel Tracking Test Results</i> (TORRES et al., 2023).

Dos 10 artigos selecionados, apenas 2 não apresentam citações em virtude de serem artigos publicados recentemente (2023), sendo estudos que ainda estão no seu estado da arte.

Esta proposta apresenta uma linha de pesquisa alinhada com o Programa de Pós-Graduação em Sistemas e Computação, integrando técnicas de aprendizado profundo de máquina. Essa integração promove o desenvolvimento de uma metodologia eficaz para detecção e classificação de defeitos superficiais em pavimentos rodoviários. Como produto final, é proposto um novo modelo para obtenção dos Índices de Condições do Pavimento e um novo método para Levantamentos Visuais Contínuos (LVC).

2.1.1 PROBLEMA A SER ABORDADO

O problema central da Proposta permeia a necessidade do aprimoramento das técnicas de supervisão/manutenção/conservação dos pavimentos rodoviários, sejam elas no âmbito público ou privado. O aprimoramento dos métodos, especialmente no que diz respeito a conservação e manutenção dos ativos rodoviários, tendo em vista o constante crescimento das frotas de veículos de diversas categorias e os frequentes relato do desgaste precoce dos dessas estruturas.

Após a revisão da literatura sobre a utilização de redes neurais para identificação patológicas nas camadas superficiais dos pavimentos, a qual será explorada no Capítulo 3, foram identificadas algumas lacunas que indicam áreas propensas a aprimoramentos. Embora os métodos elementares dos estudos encontrados tenham apresentado bons resultados em alguns casos, na sua grande maioria só realizam identificação do tipo binária e de apenas um tipo de patologia, ou seja, se há ou não trincas/fissuras na camada de rolamento. Pontos específicos dos estudos carecem de melhorias, como: classificação de mais de um tipo de defeito; grau de severidade; volume de dados mais denso e de melhor qualidade; interface amigável sistema/usuário; novos métodos e métricas para captação de dados; ausência de testes padronizados para validar os resultados; confecção de parecer técnico demonstrando os resultados, o que constitui ausência de aplicabilidade do método em escala.

Desta forma, a resolução desses problemas destaca a necessidade de um método inovador que não apenas identifique os defeitos, mas que também gere dados relevantes para o apoio a tomada de decisão em contextos complexos e dinâmicos.

2.1.2 OBJETIVO

O objetivo desta Proposta é desenvolver um método inovador para inspeção de pavimentos rodoviários (camada de rolamento) mesclando os normativos existentes com redes neurais profundas para identificação e classificação dos defeitos existentes.

Ademais, propor um incremento nos relatórios de Índice de Condição do Pavimento (ICP) e Levantamento Visual Contínuo (LVC) que foram formulados pelo Instituto de Pesquisas Rodoviárias (IPR) juntamente ao DNIT. Tais incrementos tem como objetivo gerar informações relevantes a cerca das condições da camada de rolamento e para validação dos dados processados pelas redes neurais. As novas variáveis introduzidas serão chamadas de Índice de Condição Prévia do Pavimento (ICPP) e Levantamento Visual Contínuo Digital (LVCD).

2.1.3 JUSTIFICATIVA

A infraestrutura rodoviária desempenha um papel crucial no desenvolvimento socioeconômico de uma nação, e a eficiente supervisão, manutenção e conservação dos pavimentos rodoviários são elementos fundamentais para garantir a segurança e a durabilidade dessas estruturas. O constante aumento das frotas de veículos e os relatos frequentes de desgaste precoce dos pavimentos destacam a urgência de aprimorar as técnicas existentes nesse contexto.

A revisão da literatura revelou lacunas significativas no uso de redes neurais para identificação de patologias nas camadas superficiais dos pavimentos. Embora os métodos existentes tenham apresentado resultados promissores em alguns casos, muitas limitações foram identificadas, como a abordagem binária na identificação de defeitos e a falta de capacidade para classificar múltiplos tipos de patologias, graduar a severidade, lidar com volumes densos de dados e oferecer uma interface amigável ao usuário.

Nesse contexto, a presente proposta busca desenvolver um método inovador que ultrapasse as limitações atuais, não apenas identificando defeitos, mas também gerando dados relevantes para apoiar a tomada de decisões em ambientes complexos e dinâmicos. O método proposto visa mesclar normativos existentes com o poder das redes neurais profundas, proporcionando uma abordagem mais abrangente e avançada para a inspeção de pavimentos rodoviários.

Os objetivos específicos incluem a identificação e classificação de defeitos na camada de rolamento, bem como o aprimoramento dos relatórios de Índice de Condição do Pavimento (ICP) e Levantamento Visual Contínuo (LVC) desenvolvidos pelo Instituto de Pesquisas Rodoviárias (IPR) em conjunto com o DNIT. Os incrementos propostos, denominados Índice de Condição Prévia do Pavimento (ICPP) e Levantamento Visual Contínuo Digital (LVCD), têm como objetivo fornecer informações mais detalhadas sobre as condições do pavimento, validando assim os resultados processados pelas redes neurais.

Em suma, esta proposta de dissertação busca preencher uma lacuna crítica na pesquisa em supervisão e manutenção de pavimentos rodoviários, contribuindo significativamente para o avanço das técnicas existentes e, ao mesmo tempo, melhorar a eficiência e a eficácia das práticas de conservação de ativos rodoviários.

3 FUNDAMENTAÇÃO TEÓRICA E ESTADO DA ARTE

O desempenho dos pavimentos está ligado diretamente com a sua conservação e capacidade de fluxo de veículos leves ou pesados. A desintegração das suas estruturas pode ocasionar danos prematuros ou até mesmo irreversíveis, sendo necessário intervenções onerosas. O que está intimamente ligado ao bom desempenho dos pavimentos é a detecção e caracterização precoce das patologias, tornando oportuna e tempestiva a manutenção preventiva/corretiva e eficaz das estruturas atingidas (FENG et al., 2020). O surgimento das trincas/fissuras nas camadas de rolamento está entre os principais fatores que contribuem para os danos do pavimento por não serem patologias apenas superficiais mas, oriundas do comprometimento estrutural do pavimento, propagando-se por todas as camadas comprometendo sua vida útil. (DONG et al., 2016). Com o aumento constante do tráfego nas rodovias, a manutenção preventiva dos pavimentos tem sido cada vez mais importante. Portanto, a identificação prévia e os reparos preventivos podem mitigar custos e aumentar a segurança dos veículos e condutores.

A detecção das patologias no pavimento é, na grande maioria, realizada através de métodos visuais, utilizando dispositivos móveis ou não, que identificam e classificam visualmente fissuras, trincas, buracos, panelas com base nas suas características. No entanto, esses métodos já estão em desuso por apresentarem diversas limitações incluindo subjetividade, baixa precisão e inconsistência (HE et al., 2020).

Contudo, à medida que a Inteligência Artificial (AI) e o aprendizado de máquina evoluíram recentemente, as abordagens fundamentadas em visão computacional e aprendizado de máquina tornaram-se cada vez mais populares na área de detecção e classificação de fissuras em pavimentos (YOU et al., 2016), (CHA et al., 2017). Técnicas baseadas em visão computacional e aprendizado de máquina surgiram oferecendo maior precisão e eficácia na detecção, classificação e caracterização principalmente de fissuras no pavimento (ZOU et al., 2019), (JAHANGIRI; RAKHA, 2015).

3.0.1 REDES NEURAIIS CONVOLUCIONAIS

As Redes Neurais Convolucionais (CNNs) são uma classe especializada de redes neurais projetadas para tarefas de visão computacional, destacando-se por sua eficácia em processar dados bidimensionais, como imagens. Uma das principais vantagens das CNNs é

sua capacidade intrínseca de aprender e extrair características hierárquicas a partir de padrões visuais complexos, por meio de camadas convolucionais e de *pooling*. Contudo, algumas desvantagens incluem a possibilidade de *overfitting*, especialmente em conjuntos de dados pequenos, e a necessidade de conjuntos de treinamento consideráveis para evitar a extração de características específicas do conjunto de dados de treinamento (YANG et al., 2020).




FIG. 3.1: Representação simplificada de uma CNN

Redes Neurais Convolucionais (CNN) geralmente são compostas por diferentes camadas básicas, como camadas convolucionais, camadas de *pooling*, camadas totalmente conectadas, que são encadeadas sequencialmente. As camadas de convolução possuem parâmetros chamados *BiasWeight*, sendo referidos como parâmetros do modelo. A primeira camada de uma CNN é uma imagem de entrada, realiza a operação de convolução e gera um mapa de características. As camadas seguintes leem este mapa de características e geram um novo mapa de características de saída. Isso continua até alcançar as camadas finais, que realizam a classificação usando probabilidade. As camadas de convolução localizadas na frente extraem características básicas e grosseiras, e nas camadas intermediárias, elas extraem características de nível mais alto. A camada totalmente conectada, por fim, realiza a pontuação para a classificação. As camadas de convolução são computacionalmente exigentes, e as camadas totalmente conectadas são exigentes em termos de memória (PRADEEP et al., 2018).

Os principais trabalhos selecionados na revisão da literatura utilizaram, na sua grande maioria, redes neurais convolucionais para identificação dos defeitos, tendo em vista que trabalhos anteriores obtiveram resultados satisfatórios utilizando este tipo de arquitetura. Além da CNN, também foram encontrados estudos que utilizaram *Support Vector Machine* (SVM) e Árvore de Decisão.

Cao et al. (2019) utilizaram nos seus experimentos as redes neurais VGG 19, GoogLeNet e DenseNet. O Dataset consiste em aproximadamente 2.000 imagens contendo fissuras longitudinais, fissuras laterais e fissuras reticulares. No entanto, esse estudo só utilizou o método de classificação binária, ou seja, contém ou não fissuras. A rede VGG 19 apresentou um score F1 médio de 0,8886 seguido da GoogLeNet com 0,8528 e por último a DenseNet com 0,8349. No seu estudo foi verificado que a quantidades de épocas utilizadas interferem diretamente nos resultados. No entanto, o aumento desse parâmetro poderá provocar overfitting tendo em vista que a VGG 19 atingiu a saturação restando ainda 30 épocas para o término do treinamento.

Majidifard et al. (2020) utilizaram nos seus experimentos as redes YOLO e U-Net com aproximadamente 7.327 imagens. A YOLO tem a característica de eficiência em tempo real para detecção de objetos e a U-Net se mostra efetiva no que diz respeito a segmentação semântica. Para tanto, foi proposto a utilização de um modelo híbrido YOLO+U-Net para detecção e classificação das trincas nos pavimentos que se mostrou bastante eficiente. Nesse estudo, os autores desenvolveram um modelo de previsão das condições do pavimento, o que denota uma contribuição e um avanço considerável, não sendo este apenas mais um modelo de detecção. Ao fim dos experimentos, a matriz de confusão mostrou o Score F1 de aproximadamente 0,84 e classificando 8 tipos trincas.

Outra pesquisa que também utilizou as redes YOLO foi o estudo proposto por (FENG et al., 2020). Foram coletadas 3.000 amostras que foram divididas aleatoriamente para treino, teste e verificação. Foram testados os modelos YOLOv5s, YOLOv5m, YOLOv5l e YOLOv5x onde a taxa de reconhecimento de todos os modelos foi superior a 85% dentre trinca transversal, trinca por fadiga e trinca longitudinal, testados em 1000 épocas cada modelo.

Tran et al. (2021) utilizaram nos seus experimentos a arquitetura de rede RetinaNet, onde foram processadas 20.000 imagens o que corroborou com os resultados obtidos tendo em vista que a RetinaNet é uma rede que apresenta melhor resultados com Datasets acima de 5.000 imagens. A rede leva em torno de 3 horas para treinar as 20.000 imagens, no entanto, leva apenas 6 segundos para testar uma imagem em tamanho original que corresponde a 10 m de comprimento da seção do pavimento. Foram detectados os tipos de trincas e a severidade com uma acurácia de 84,9% e para detecção da sinalização horizontal 96,5%. Contudo, essa arquitetura exige uma maior capacidade computacional.

Nguyen et al. (2023) fizeram um estudo comparativo entre as redes ResNet, DenseNet e VGG 19 utilizando um Dataset de 1000 imagens sendo empregada, em alguns momentos, a técnica de aumento de dados. Os três modelos de rede apresentaram resultados de score

F1 acima de 80% quando aplicado a técnica, sendo este apenas para identificação binária.

Padmapoorani e Senthilkumar (2023) também exploraram as arquiteturas da rede VGG fazendo o uso do modelo VGG16-Net e a comparou com outra arquitetura efetivo em tarefas de visão computacional e classificação de imagens Vision Transformer (ViT). Durante o estudo, os autores também comparam o desempenho do experimento com outras redes, mas o enfoque do estudo ficou nos modelos supracitados. O Dataset envolve cerca de 20.000 imagens de estruturas de concreto e, após os experimentos, a rede VGG16-Net apresentou um melhor desempenho entregando um score F1 de 98,50% enquanto a ViT performou em 94,87%. Redes como ResNet101, InceptionResNet V2, GoogLeNet e AlexNet também performaram abaixo da VGG.

Diferente dos outros autores, (TORRES et al., 2023) exploraram patologias provenientes, na grande maioria, de rodovias sujeitas há um alto tráfego de veículos pesados que são as trilhas de rodas, consolidação ou deformação permanente. No entanto, nesse estudo foram utilizadas imagens geradas em laboratório. Foi empregado um conjunto de dados de 1.198 imagens usando os algoritmos pré-treinados como VGG-16, VGG-19, ResNet50, DenseNet121, InceptionV3 e MobileNet. Contudo, as arquiteturas VGG se sobressaíram e apresentaram uma precisão acima de 82%. Já as demais, exibiram desempenho comparativamente inferior, talvez provocada pela baixa quantidade de dados.

Wang et al. (2023) utilizaram o modelo YOLO aprimorado pelo ViT que combina o transformador de visão e o modelo YOLO V5 para localização e classificação de fissuras em pavimentos asfálticos. Para os experimentos foram coletadas 1.944 imagens de pavimentos asfálticos através de varredura linear. Também foram adicionados ruído as imagens a fim de simular chuva, ainda assim, os resultados foram satisfatórios e promissores. O treinamento foi realizado com a rede sem e com o ViT e os modelos que se destacaram em ambos os testes foram o YOLO V5m e YOLO V5m-t com uma precisão de 0,897 e 0,889 respectivamente.

Por se tratar de arquiteturas que não compõem as redes neurais convolucionais, tanto a SVM quanto a LightGBM ficaram destacadas a seguir. A ViT também não faz parte da classe das CNN, mas nos outros estudos ela ficou sendo utilizada como uma rede neural secundária.

Hoang et al. (2022) optaram por utilizar o modelo de rede SVM por sua capacidade em classificação de dados não linear e multivariada ter sido demonstrada em diversos estudos. Para aplicação do modelo foram coletadas 300 amostras de superfícies de pavimento asfáltico. Além disso, os autores agregaram ao modelo o *Slap Swarm Algorithm* (SSA) proposto como uma abordagem para otimização global e local de funções. O método iden-

tifica características binárias de presença de trinca ou trincas seladas e para treinamento destinou 90% dos dados, quanto para teste apenas 10%. O treinamento/teste foi repetido 20 vezes e apresentou um score F1 de 0,87.

Hoang e Nguyen (2023) como citado anteriormente, utilizaram no seu estudo um *framework* pertencente a categoria de métodos de aprendizado de máquina, especificamente a família de métodos de impulso gradiente conhecido como LightGBM que foi comparado a arquiteturas DNN e CNN. Para treinar e verificar os modelos, foi criado um *Dataset* composto por 12.000 amostras e seis rótulos de classes. Também foi incrementado ao estudo duas ferramentas estatísticas, Kappa de Cohen e Teste de Wilcoxon que avaliam a concordância e comparam as amostras. O conjunto de dados foi separado em 70% para treino e 30% para teste. Nas seis classes propostas no estudo os coeficientes Kappa foram superiores a 90% de acerto.

3.0.2 PAVIMENTOS RODOVIÁRIOS

Segundo (BERNUCCI et al., 2022), o pavimento rodoviário é uma estrutura de múltiplas camadas de espessuras finitas, construída sobre a superfície final de terraplenagem, destinada a resistir aos esforços provocados pelo tráfego de veículos e do clima. Segundo o mesmo autor, o pavimento viário classifica-se tradicionalmente em dois tipos: rígidos e flexíveis.




FIG. 3.2: Estrutura de pavimentos

O pavimento rígido é composto por um revestimento de concreto de cimento Portland que formam placas, podendo ser armada com barras de aço ou não, com dimensões e resistências específicas. Já o pavimento flexível (asfálticos) é composto por uma mistura constituída basicamente de agregados, filler e ligantes asfálticos e, é formado por quatro camadas principais: revestimento asfáltico, base, sub-base e reforço do sub-leito. Essas estruturas são submetidas constantemente a tensões verticais, horizontais e de carga circular que provocam deformações permanentes ou não. FIG. 3.2

Diversos fatores podem contribuir para o desgaste prematuro dessas estruturas, principalmente na camada superficial. Os defeitos de superfície podem surgir precocemente por erros de projeto ou de execução ou, a médio e longo prazo, em função do tráfego e intempéries.

Os defeitos de superfície ou patologias superficiais, são danos ou deteriorações que podem ser identificadas a "olho nu" e são classificados de acordo com a norma (DNIT 005/2003-TER-DNIT, 2003a) (DNIT, 2003).

A norma **DNIT 005/2003-TER: Defeitos nos pavimentos flexíveis e semirrígidos: terminologia**, classifica os tipos de defeitos em: fendas (F); afundamentos (A); corrugação e ondulações transversais (O); exsudação (EX); desgaste ou desagregação (D); panela ou buraco (P); e remendos (R). A Tabela 3.1 detalha os tipos e suas características.

DEFEITOS	DESCRIÇÃO
Fendas (F)	Aberturas na superfície asfáltica que podem ser classificadas como fissuras ou trincas de acordo com a abertura.
Afundamentos (A)	Derivados de deformações permanentes do revestimento asfáltico ou das camadas subjacentes.
Corrugação e Ondulações transversais (O)	São deformações transversais ao eixo da pista com depressões intercaladas de elevação.
Exsudação (EX)	Caracterizada pelo surgimento de ligante em abundância na superfície, com o aparecimento de manchas escuras.
Desgaste ou desagregação (D)	Desprendimento de agregados da superfície ou perda de mástico junto aos agregados.
Panela ou Buraco (P)	Cavidade no revestimento asfáltico, podendo ou não atingir camadas subjacentes.
Escorregamento (E)	Decorrente da fluência do revestimento asfáltico.
Remendo (R)	É considerado um defeito mesmo sendo uma prática de conservação para preenchimento de painéis ou outros orifícios.

TAB. 3.1: Tipos de defeitos - pavimentos flexíveis

Os defeitos característicos do pavimento rígido são classificados pela norma **DNIT 061/2004-TER: Pavimento rígido - Defeitos - Terminologia**, que são decorrentes de-

corrente de problemas na fundação, de má execução ou do uso do pavimento. Os tipos de defeitos são: alçamento de placas; fissura de canto; placa dividida; escalonamento ou degrau nas juntas; falha na selagem das juntas; desnível pavimento; fissuras lineares; grandes reparos; pequenos reparos; desgaste superficial; bombeamento; quebras localizadas; passagem de nível; fissuras superficiais; fissuras de retração plástica; esborcinamento ou quebra de canto; esborcinamento de juntas; placa "bailarina"; assentamento; e buracos. A descrição de cada defeito está disposto na Tabela 3.2.

DEFEITOS	DESCRIÇÃO
Alçamento de placas	Desnivelamento das placas nas juntas ou nas fissuras transversais.
Fissura de canto	Fissura que intercepta as juntas a uma distância menor ou igual à metade do comprimento das bordas ou juntas do pavimento (longitudinal e transversal).
Placa dividida	A placa que apresenta fissuras dividindo-a em quatro ou mais partes.
Escalonamento ou degrau nas juntas	Ocorrência de deslocamentos verticais diferenciados e permanentes entre uma placa e outra.
Falha na selagem das juntas	Avaria no material selante que possibilite o acúmulo de material incompressível na junta ou que permita a infiltração de água.
Desnível do pavimento	Degrau formado entre o acostamento e a borda do pavimento.
Fissuras lineares	Fissuras que atingem toda a espessura da placa de concreto, dividindo-a em duas ou três partes.
Grandes reparos	Área do pavimento original maior que 0,45m ² , que foi removida e posteriormente preenchida
Pequenos reparos	Área do pavimento original menor ou igual a 0,45m ² , que foi removida e posteriormente preenchida.
Desgaste superficial	Descolamento da argamassa superficial, fazendo com que os agregados aflorem na superfície.
Bombeamento	Expulsão de finos plásticos existentes no solo de fundação do pavimento, através das juntas, bordas ou trincas.
Quebras localizadas	Áreas das placas que se mostram trincadas e partidas em pequenos pedaços.
Passagem de nível	Ocorrem em passagens de nível, consistindo de depressões ou elevações próximas aos trilhos.
Fissuras superficiais	São fissuras capilares que ocorrem apenas na superfície da placa, tendo profundidade entre 6mm e 13mm.
Fissuras de retração plástica	Fissuras pouco profundas (superficiais), de pequena abertura (inferior a 0,5mm) e de comprimento limitado.
Esborcimento ou quebra de canto	Quebras que aparecem nos cantos das placas, tendo forma de cunha.
Esborcimento de juntas	Quebra das bordas da placa de concreto (quebra em cunha) nas juntas, com o comprimento máximo de 60cm.
Placa "bailarina"	Placa cuja movimentação vertical é visível sob a ação do tráfego.
Assentamento	Afundamento do pavimento, criando ondulações superficiais de grande extensão.
Buracos	Reentrâncias côncavas observadas na superfície da placa, provocadas pela perda de concreto no local.

TAB. 3.2: Tipos de defeitos - pavimentos rígidos

Dessa forma, ficam dispostos todos os defeitos que contemplam tanto os pavimen-

tos flexíveis quanto os rígidos que condicionam a avaliação da superfície bem como as possíveis causas e efeitos. Tais definições também contribuem para inspeções visuais e para formação dos graus de severidade dos defeitos também definidos pelos normativos do DNIT.

4 A PROPOSTA

4.1 OBJETIVOS E QUESTÕES DE PESQUISA

A fim de aprimorar a eficácia nos processos de inspeção em pavimentos rodoviários nas mais diversas organizações públicas ou privadas, a aplicação de técnicas que envolvem elementos tecnológicos, a exemplo, a utilização de inteligência artificial e suas derivações se tornam um meio para o surgimento de novos métodos em análise dos índices de condições dos pavimentos sejam eles flexíveis, rígidos ou semi-rígidos. O alto volume de rodovias existentes denotam os desafios e complexidades existentes para que as estruturas dos pavimentos se mantenham integras e com boas condições de trafegabilidade, tendo em vista que as métricas de análises mais usuais não incorporam técnicas mais refinadas em detrimento da subjetividade intrínseca ao processo. Diante deste contexto, a proposta de desenvolver uma nova metodologia de análise de condições dos pavimentos com a utilização de técnicas de *Machine Learning* (ML), surge como uma proposta promissora a mitigar as lacunas e limitações existentes nas técnicas tradicionais. A metodologia proposta integra técnicas avançadas que visa oferecer soluções mais eficiente que auxiliem na tomada de decisão, mais especificamente qual o tipo de intervenção será necessária naquele cenário exposto. Diante deste contexto, as seguintes questões de pesquisas são propostas para guiar o desenvolvimento e avaliação do novo método:

Questão de Pesquisa 1. *Como a implementação de novas técnicas de (ML), mais especificamente o uso de aprendizado profundo com redes neurais convolucionais, pode aprimorar os métodos de análise de condições dos pavimentos tradicionais?*

Questão de Pesquisa 2. *Quais as vantagens e possíveis limitações do novo método proposto em comparação com os métodos já existentes para análises das condições da camada de rolamento dos pavimentos em termos de eficiência, eficácia e precisão em diversos cenários?*

Após a revisão da literatura foram encontrados diversos resultados e técnicas de aprendizado profundo de máquina, sendo os mais usuais os algoritmos de redes neurais convolucionais. Dessa forma, é possível algumas tendências e limitações dos modelos:

- Redes Neurais Convolucionais: a grande maioria dos trabalhos analisados fazem o uso de redes neurais convolucionais, sendo as de maiores destaques a VGG e a

YOLO com modelos que entregam uma maior acurácia;

- Detecção e classificação: alguns modelos apresentaram apenas a detecção binária, ou seja, há ou não trincas na superfície e, conseqüentemente, não classificou outras patologias e as sua severidades;
- Obtenção do *Dataset*: a presença de *Datasets* reduzidos resultou em experimentos com baixa acurácia bem como a presença de *overfitting*. Além disso, *dataset* com imagens de baixa qualidade ou com grande quantidade de ruídos também dificultaram o aprendizado dos modelos;
- Outras técnicas de aprendizado de máquina: alguns estudos apresentaram a utilização de outras técnicas de aprendizado de maquina como: SVM, LightGBM e Árvore de Decisão. Tais técnicas apresentaram bons resultados, no entanto, limitaram-se a classificações binárias.

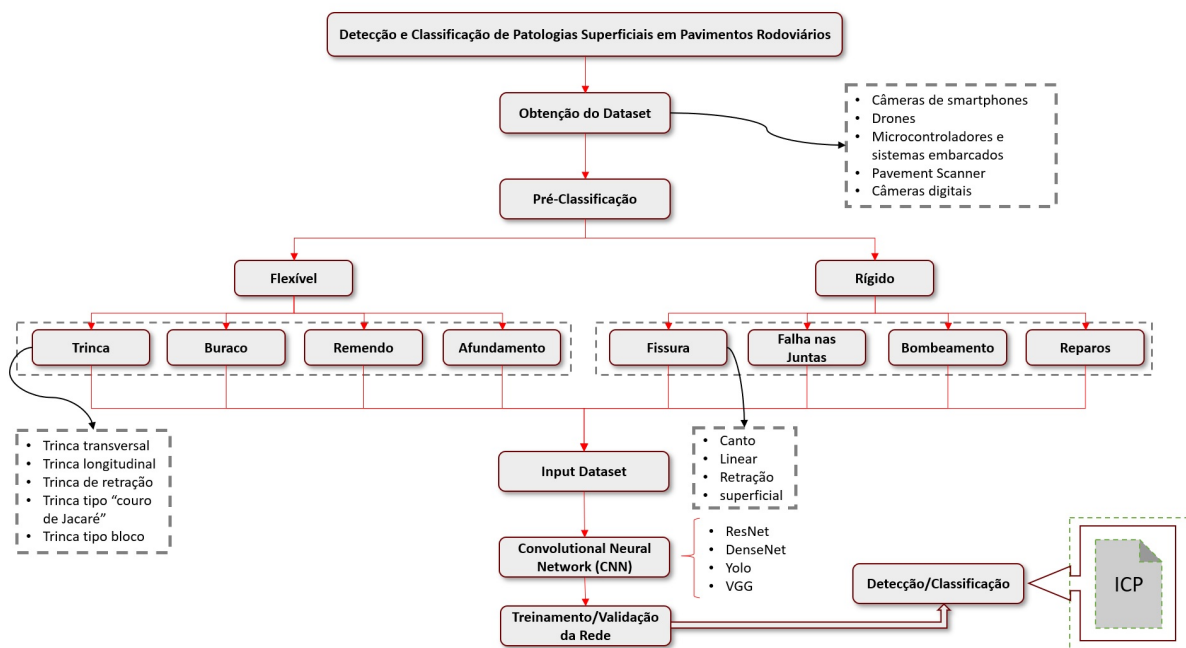


FIG. 4.1: Fluxograma

Diante do disposto, esta proposta se fundamenta na elaboração de um novo método de inspeção rodoviária para elaboração de um índice de condição do pavimento, seja ele flexível ou rígido, seguindo o fluxograma disposto na FIG. 4.1, que dispõe do seguinte fluxo:

- Obtenção do *Dataset*: Os dados para treinamento do modelo é obtido através de diversos métodos podendo até ser de bases externas como *Kaggle* e *GitHub*. No entanto, é necessário que se tenha um número considerável de imagens a fim de garantir resultados satisfatórios durante o treino/validação do modelo. No caso proposto as imagens são advindas de levantamentos realizados por Drones e pelo *Pavement Scanner*.
- Pré-classificação do *Dataset*: após a obtenção do dataset se faz necessário uma pré classificação das imagens para separa-las em *clusters* tendo em vista que o modelo propõe analisar pavimentos tanto flexíveis quanto rígidos. Além disso, cada tipo apresenta as suas características patológicas destacadas a seguir.
- Flexível: Os pavimentos flexíveis apresentam, segundo a Norma 006/2003 do DNIT, inicialmente 7 tipos de patologias superficiais sendo elas: trincas, afundamento, es-corregamento, exsudação, desgastes e panela. Para o modelo proposto foram con-templados as trincas e suas variações, buracos/panelas, remendos e os afundamentos
- Rígido: Já os pavimentos rígidos apresentam número maior de classificações. Se-gundo a Norma 060/2003 - DNIT (Anexo E), são apresentados 20 possíveis defeitos que podem ser encontrados neste tipo de pavimento. Em virtude da complexidade e do custo computacional para classificar todas as características, para essa proposta foram selecionadas quatro patologias: fissuras, falha nas juntas, bombeamento e reparos.
- *Input Dataset*: Após a classificação dos *clusters* todas as imagens são carregadas no modelo de rede neural para o efetivo treinamento da rede que apresente os melhores rendimentos.
- Escolha da Rede Neural: A escolha da rede neural será baseada nos testes feito utilizando o mesmo *Dataset* e os mesmos hiper parâmetros a fim de comparar qual irá apresentar os melhores resultados de acurácia de teste e validação. As redes em teste são aquelas que apresentaram resultados satisfatórios em outros estudos, sendo as de maior destaque a VGG e a YOLO.
- Treinamento/Validação: As imagens foram classificadas e após a definição dos hiper parâmetros as redes são treinadas. Esta etapa depende totalmente da quantidade e da qualidade dos dados. Segundo (TRAN et al., 2021), Quando mais dados para

aprendizagem e treinamento, melhores resultados de detecção podem ser obtidos. No entanto, construir um conjunto de dados robusto demanda tempo.

- Detecção/Classificação: Após o treinamento, um modelo treinado é gerado com a quantidade de épocas definidas no treinamento. Dessa forma, o modelo da rede selecionada faz a detecção da presença da patologia e classifica de acordo com os *clusters* definidos em etapas anteriores.
- Relatório ICPP/LVCD: a etapa final consiste na elaboração do relatório que indica o Índice de Condição Prévio do Pavimento.

Entende-se que o emprego do método, quando aplicado de forma concisa, apresenta um grande potencial de revolucionar os segmentos de inspeção, conservação/manutenção, bem como o gerenciamento de rodovias.

O *framework* proposto pretende simplificar e agilizar os processos de inspeção de pavimentos, sejam eles rígidos ou flexíveis, mitigando erros, aumentando a eficácia e eficiência, diminuindo os riscos oferecidos nos métodos mais tradicionais, reduzir custos em comparação aos métodos mais robustos utilizados atualmente e, por fim, auxiliar na tomada de decisão de qual a melhor intervenção a ser proposta caso a caso.

4.1.1 HIPÓTESES

Este trabalho tem por objetivo criar um novo método de inspeção de pavimentos rodoviários. Este método propõe a utilização de técnicas de ML para o auxílio de detecção e classificação de patologias superficiais nos pavimentos rígido e flexíveis, possibilitando a confecção de novos métodos inspeções visuais, bem como para levantamentos visuais contínuos e até mesmo contribuindo para surgimento do Índice de Condição Prévio do Pavimento (ICPP).

Hipótese 1. *A utilização de redes neurais para identificação de patologias, em conjunto com a metodologia proposta, possibilitará uma análise mais eficaz, eficiente e segura. O método permite a automação de diversos pontos existentes nos processos de inspeção/levantamento de rodovias tradicionais como a obtenção dos dados, processamento dos dados e classificação dos problemas existentes na camada superficial do pavimento mitigando, desta forma, a subjetividade do operador e auxiliando na tomada de decisão.*

A hipótese de que a utilização de redes neurais para identificação de patologias em pavimentos rodoviários, associada à metodologia proposta, promove uma análise mais eficaz, eficiente e segura e se sustenta na abordagem automatizada processos de inspeção,

como coleta, processamento e classificação de dados, o que reduz a subjetividade humana. A eficiência na manipulação de grandes volumes de dados, a capacidade de lidar com padrões complexos e a minimização da subjetividade contribuem para uma análise mais objetiva, auxiliando na tomada de decisão e otimização da manutenção rodoviária. Em suma, a combinação de redes neurais e metodologia proposta representa uma abordagem inovadora e vantajosa em comparação aos métodos tradicionais de inspeção de rodovias.

Hipótese 2. *A proposta visa oferecer um novo método de para identificação e classificação de patologias com redes neurais que não sejam apenas binárias, possibilitando a análise de mais de um tipo de patologia existente na camada superficial do pavimento. A utilização do aprendizado profundo de máquina tem sido promissor e pode garantir a eficácia do modelo proposto.*

A hipótese propõe um novo método para identificação e classificação de patologias em pavimentos rodoviários, utilizando redes neurais não binárias. Ao contrário dos métodos tradicionais, a abordagem permite analisar múltiplos tipos de patologias na superfície do pavimento. A eficácia do modelo é respaldada pelo uso do aprendizado profundo de máquina, destacando-se pela capacidade de capturar nuances complexas nos dados. A trajetória promissora do aprendizado profundo em outras áreas reforça a viabilidade dessa abordagem inovadora para melhorar a identificação de patologias em rodovias.

4.2 CONTRIBUIÇÕES ESPERADAS

Levando em consideração a revisão da literatura realizada, a proposta de dissertação se destaca pela aplicação das redes neurais convolucionais, com foco em identificação e classificação de patologias em pavimentos rodoviários. O trabalho propõe não só a detecção dos problemas, nem apenas a classificação binária da presença de trincas ou não. Além disso, é proposto a classificação de outros tipos de patologias tanto em pavimentos flexíveis quanto nos pavimentos rígidos. Não obstante, o modelo também contempla a implementação de um novo método de análise do Índice de Condição Prévio do Pavimento (ICPP) baseado no (ICP), bem como do Levantamento Visual Contínuo (LVC).

As contribuições esperadas para este trabalho são:

- (i) Utilização de redes neurais convolucionais com modelos pré-treinados aplicando as técnicas de *transfer learning* e *fine-tuning* para obtenção dos melhores resultados.
- (ii) Criação de um novo método de inspeção e gerenciamento rodoviário baseado nos normativos do Departamento Nacional de Estradas e Rodagens (DNIT) de avaliação

objetiva, levantamento visual e inspeção visual.

- (iii) Incorporação de métodos autônomos aos modelos de inspeção já existentes, bem como a redução nos riscos de acidentes, diminuição da subjetividade e redução nos custos de operação.
- (iv) Integração nos métodos de obtenção dos dados utilizando diversos equipamentos como: Drones, *smartphones*, microcontroladores e sistemas embarcados, câmeras de alta definição com GPS integrado.
- (v) Exploração de plataformas que possibilitem a criação de sistemas de fácil manuseio e interação com o usuário.
- (vi) Estabelecimento de uma abordagem mais abrangente englobando diversas métricas trazendo a possibilidade de expansão do modelo e o surgimento de novos *insights*.

As contribuições elencadas acima tem a capacidade de fornecer uma metodologia robusta no que diz respeito a inspeção de pavimentos rodoviários impactando inclusive nas tomadas de decisões apresentando vantagens em termos de eficiência, precisão, celeridade mitigando variáveis que muitas das vezes são negligenciadas nos modelos convencionais em detrimento da subjetividade.

5 PLANO DE AÇÃO

Esta Proposta seguirá um conjunto de atividades pré-definidas de acordo com o descrito na TAB. 5.1

TAB. 5.1: Atividades planejadas.

Posição	Atividades
1	Revisão Bibliográfica
2	Obtenção dos dados
2	Classificação do banco de dados
3	Testes das principais redes neurais encontradas
4	Treinamento exaustivo da rede neural
5	Obtenção dos resultados parciais e escrita do artigo
6	Desenvolvimento do script dos relatórios ICPP/LVCD
7	Validação do método através de aplicações praticas
8	Escrita do artigo com os resultados das aplicações
9	Escrita da dissertação
10	Defesa

5.1 METODOLOGIA

A Proposta é composta por uma abordagem metodológica que integra técnicas de aprendizado de máquina com ênfase em redes neurais convolucionais para alcançar os objetivos dispostos anteriormente. Inicialmente, foi realizado um levantamento bibliográfico para consolidação da base teórica necessária. Consequente, foi realizada a obtenção dos dados. Fase esta importante em virtude de os modelos de aprendizado profundo exigirem uma densa massa de dados para que se obtenha bons resultados e refute o surgimento de *overfitting*.

Após a obtenção dos dados, se fez necessário uma pré-classificação para separação dos *clusters* de cada tipo de pavimento. Como o modelo proposto almeja além da identificação da alguma patologia a sua classificação, a pré-classificação é de suma importância para o treinamento da rede.

Munido das informações obtidas através da revisão bibliográfica, foi possível identificar quais as principais redes neurais estão sendo utilizadas para resolver o tipo de problema proposto. Como já dito anteriormente, as redes mais recorrentes foram a VGG

e a YOLO. No entanto, os teste preliminares foram realizados com redes neurais de menor capacidade como a GoogLeNet, SqueezeNet e Inception devido a exigência de menor custo computacional. Para os testes foi utilizado o software *MatLab* que dispõe os algoritmos de redes neurais pré-treinados e de fácil manuseio. Contudo, os resultados obtidos não foram satisfatório. Portanto, esta fase da pesquisa passará por novos testes.

Também se faz necessário o treinamento exaustivo da rede com a variação dos hiper parâmetros a fim de se obter a melhor configuração possível para garantir que a rede neural não esteja decorando as características das imagens e sim aprendendo. Os treinamentos serão realizados com o mesmo banco de dados variando os parâmetros de *Learning Rate*, *Epoch*, *Wheigth*, *Iteration* e, caso seja necessário, a utilização da técnica de *Data Agumentation*. Há também a pretensão do uso de software como *Python* e *keras* para os modelos de aprendizado profundo.

Após a obtenção dos resultados preliminares, será confeccionado um artigo científico com o objetivo de mostrar para comunidade acadêmica os avanços alcançados utilizando o método adotado, demonstrando também a vantagens, desvantagens e desafios encontrados.

Intrínseco a proposta também há o desenvolvimento dos relatórios que demonstram os resultados finais do método proposto gerando dois produtos baseados nos normativos do Departamento Nacional de Infraestrutura de Transporte (DNIT). Diante dos resultados obtidos, será utilizado um *framework* para construção de uma interface que permita a integração dos dados para construção de um relatório que demonstre o que será denominado de Índice de Condições Prévia do Pavimento (ICPP). Um segundo produto será um relatório de Levantamento Visual Contínuo Digital (LVCD), também baseado nos normativos do DNIT.

Paralelamente, todos passos do cronograma serão validados através de aplicações práticas para que se obtenha resultados robustos e confiáveis. Os resultados das aplicações também serão submetidos a comunidade acadêmica com intuito de contribuir mostrando os resultados, positivos ou não, do método em questão. Além disso, estes resultados já permitem o desenvolvimento simultâneo da redação da dissertação tendo em vista que os mesmos já fazem parte do estudo. O que consolidará os fundamentos teóricos, a metodologia adotada e os resultados obtidos que, além de contribuir com um novo método para área de Computação e Transporte Rodoviário, culminará na defesa da dissertação.

5.2 CRONOGRAMA

O cronograma para o desenvolvimento das atividades relacionadas a esta proposta pode ser visto na Figura 5.1.

Atividades	2023				2024											
	set	out	nov	dez	jan	fev	mar	abr	mai	jun	jul	ago	set	out	nov	dez
Revisão Bibliográfica																
Obtenção dos dados																
Classificação do banco de dados																
Testes das principais redes neurais encontradas																
Treinamento exaustivo da rede neural																
Obtenção dos resultados parciais e escrita do artigo																
Desenvolvimento do script dos relatórios ICPP/LVC																
Validação do método através de aplicações praticas																
Escrita do artigo com os resultados das aplicações																
Escrita da dissertação																
Defesa																

FIG. 5.1: Cronograma da Proposta de Dissertação.


Na Figura 5.1 é apresentado o cronograma relacionado as respectivas atividades apresentadas. Em destaque verde estão as etapas que já foram vencidas e, em azul, as etapas planejadas.

6 REFERÊNCIAS BIBLIOGRÁFICAS

- ASHRAF, A.; SOPHIAN, A.; SHAFIE, A. A.; GUNAWAN, T. S. ; ISMAIL, N. N. Machine learning-based pavement crack detection, classification, and characterization: a review. **Bulletin of Electrical Engineering and Informatics**, v. 12, p. 3601–3619, 2023.
- BERNUCCI, L. B.; MOTTA, L. M. G.; CERATTI, J. A. P. ; SOARES, J. B. Pavimentação asfáltica - formação básica para engenheiros. **ABEDA**, v. 2^o Edição, p. 756, 2022.
- CAO, W.; ZOU, Y.; LUO, M.; ZHANG, P.; WANG, W. ; HUANG, W. Deep discriminant learning-based asphalt road cracks detection via wireless camera network. In: 2019 COMPUTING, COMMUNICATIONS AND IOT APPLICATIONS (COMCOMAP), 2019., 2019. **Anais...** [S.l.: s.n.], 2019, p. 53–58.
- CHA, Y. J.; CHOI, W. ; BÜYÜKÖZTÜRK, O. Deep learning-based crack damage detection using convolutional neural networks. **Computer-Aided Civil and Infrastructure Engineering**, v. 32, p. 361–378, 2017.
- COSTAS, E. L.; BENATTI, F.; FILHO, R. H. C.; FILHO, J. F. F.; JÚNIOR, P. G.; BATISTA, B. ; BATISTA, B. **Pesquisa CNT de Rodovias 2023**. [S.l.: s.n.], 2023. ISBN 9788568865132.
- DNIT. **NORMA 005/2003 - TER - Defeitos nos pavimentos flexíveis e semi-rígidos Terminologia**. [S.l.: s.n.], 2003.
- DNIT. **NORMA 006/2003 - PRO - Avaliação objetiva da superfície de pavimentos flexíveis e semi-rígidos-Procedimento**. [S.l.: s.n.], 2003.
- DNIT. **NORMA 060/2004 - PRO - Pavimento rígido-Inspeção visual-Procedimento**. [S.l.: s.n.], 2004.
- DONG, Z.; YE, S.; GAO, Y.; FANG, G.; ZHANG, X.; XUE, Z. ; ZHANG, T. Rapid detection methods for asphalt pavement thicknesses and defects by a vehicle-mounted ground penetrating radar (gpr) system. **Sensors (Switzerland)**, v. 16, p. 2067, 2016.

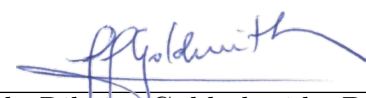
- FENG, X.; XIAO, L.; LI, W.; PEI, L.; SUN, Z.; MA, Z.; SHEN, H. ; JU, H. Pavement crack detection and segmentation method based on improved deep learning fusion model. **Mathematical Problems in Engineering**, v. 2020, p. 1–22, 2020.
- HE, G.; XIE, Y. ; ZHANG, B. Expressways, gdp, and the environment: The case of china. **Journal of Development Economics**, v. 145, p. 66, 2020.
- HOANG, N. D.; HUYNH, T. C.; TRAN, X. L. ; TRAN, V. D. A novel approach for detection of pavement crack and sealed crack using image processing and salp swarm algorithm optimized machine learning. **Advances in Civil Engineering**, v. 2022, p. 21, 2022.
- HOANG, N. D.; NGUYEN, Q. L. Computer vision-based recognition of pavement crack patterns using light gradient boosting machine, deep neural network, and convolutional neural network. **Journal of Soft Computing in Civil Engineering**, v. 7, p. 21–51, 2023.
- JAHANGIRI, A.; RAKHA, H. A. Applying machine learning techniques to transportation mode recognition using mobile phone sensor data. **IEEE Transactions on Intelligent Transportation Systems**, v. 16, p. 2406–2417, 2015.
- MAJIDIFARD, H.; ADU-GYAMFI, Y. ; BUTTLAR, W. G. Deep machine learning approach to develop a new asphalt pavement condition index. **Construction and Building Materials**, v. 247, p. 31, 2020.
- NGUYEN, S. D.; TRAN, T. S.; TRAN, V. P.; LEE, H. J.; PIRAN, M. J. ; LE, V. P. Deep learning-based crack detection: A survey. **International Journal of Pavement Research and Technology**, v. 16, p. 943–967, 2023.
- PADMAPOORANI, P.; SENTHILKUMAR, S. Application of machine learning for crack detection on concrete structures using cnn architecture. **Revista Materia**, v. 28, p. 16, 2023.
- PRADEEP, K.; KAMALAVASAN, K.; NATHEESAN, R. ; PASQUAL, A. **EdgeNet: SqueezeNet like Convolution Neural Network on Embedded FPGA**. [S.l.: s.n.], 2018. 81-84 p.
- TORRES, J. A. G.; ROSALES, L. A. M.; BADILLO, I. A.; GUERRERO, G. T.; BÁEZ, M. L. ; BARRIGA, J. O. M. Deep learning techniques for multi-class classification

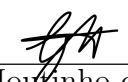
- of asphalt damage based on hamburg-wheel tracking test results. **Case Studies in Construction Materials**, v. 19, p. e02378, 2023.
- TRAN, V. P.; TRAN, T. S.; LEE, H. J.; KIM, K. D.; BAEK, J. ; NGUYEN, T. T. One stage detector (retinanet)-based crack detection for asphalt pavements considering pavement distresses and surface objects. **Journal of Civil Structural Health Monitoring**, v. 11, p. 205–222, 2021.
- WANG, S.; CHEN, X. ; DONG, Q. Detection of asphalt pavement cracks based on vision transformer improved yolo v5. **Journal of Transportation Engineering, Part B: Pavements**, v. 149, p. 9, 2023.
- YANG, G.; WANG, K. C. P.; LI, J. Q.; FEI, Y.; LIU, Y.; MAHBOUB, K. C. ; ZHANG, A. A. Automatic pavement type recognition for image-based pavement condition survey using convolutional neural network. **Journal of Computing in Civil Engineering**, v. 35, p. 04020060, 2020.
- YOU, Z.; ZHOU, J.; WANG, Y.; SUN, Z.; SHAN, S.; ZHENG, W.; FENG, J. ; ZHAO, Q., editores. **Biometric Recognition**. [S.l.]: Springer International Publishing, 2016. ISBN 978-3-319-46653-8.
- ZOU, Q.; ZHANG, Z.; LI, Q.; QI, X.; WANG, Q. ; WANG, S. Deepcrack: Learning hierarchical convolutional features for crack detection. **IEEE Transactions on Image Processing**, v. 28, p. 1498–1512, 2019.


Danilo Marcus Farias Marinho do Monte (SC 23110)
Aluno

Capitão de Fragata Marcos dos Santos, Ph.D.

Orientador


Ronaldo Ribeiro Goldschmidt, D.Sc.
Co-orientador


Major Gabriela Mourinho de Souza Dias, D.Sc.
Coordenador de Pós-graduação

Concordo com a presente Proposta de Dissertação e declaro que as necessidades para sua execução serão garantidas pela Seção.

IME, em 19 de fevereiro de 2024.


Cel Julio Cesar Duarte
CHEFE da SE/9